ВНИМАНИЕ!

ДАННЫЙ КУРС СОДЕРЖИТ БОЛЬШОЕ КОЛИЧЕСТВО РАЗНООБРАЗНОГО КОДА И ЗАДАНИЙ ДЛЯ САМОСТОЯТЕЛЬНОГО РЕШЕНИЯ.

НА ПЕРВЫЙ ВЗГЛЯД ОН МОЖЕТ ПОКАЗАТЬСЯ СЛОЖНЫМ И ТРАВМИРОВАТЬ НЕПОДГОТОВЛЕННУЮ ПСИХИКУ. ТАКЖЕ ОН СОДЕРЖИТ БОЛЬШОЕ КОЛИЧЕСТВО НЕУДАЧНЫХ ШУТОК И НЕУМЕСТНЫХ ОТСЫЛОК.

В СВЯЗИ С ЭТИМ КУРС НЕ РЕКОМЕНДУЕТСЯ ПРОСЛУШИВАТЬ … НИКОМУ.

Глубокое обучение и вообще

Ульянкин Филипп

20 июня 2021 г.

Посиделка 1: вводная

Я

Agenda

- О том каким будет курс + что почитать/посмотреть
- Фреймворки для нейроночек
- Немного истории и важные тренды
- От регрессии к нейросетке
- Нейросетки — конструктор Lego
- Вводимся в Tensorflow

Правила игры и почиташки

Про пары

- что-то неясно $\Rightarrow$ ПЕРЕБЕЙ И СПРОСИ
- на парах смотрим презы, пишем код, решаем задачи
- все материалы можно найти на страничке курса

Что почитать про нейронки в первую очередь

Баланс математики и практики, код устарел (tensorflow 1.14)

Философия и история ML

Что почитать про нейронки в первую очередь

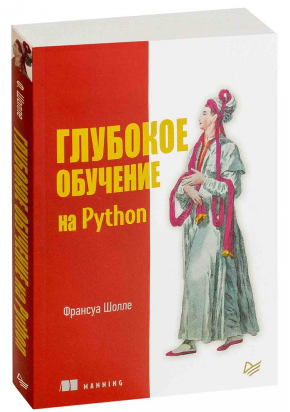

Простая практика на Keras

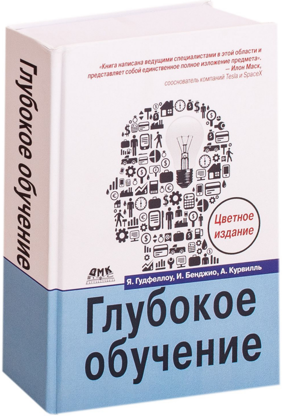

Хардкорная математика,
библия глубокого обучения

Что посмотреть про нейронки

- Deep learning на пальцах. Лекции из кремниевой долины. Задания на pytorch для самостоятельного решения. Для тех, кто хочет мало математики и понимания что происходит.

- Бесплатный курс по pytorch от Samsung. Вводный курс в нейросетки на pytorch. Состоит из двух частей: CV и NLP. Для тех, кто хочет писать на pytorch.

- Advanced ML от Яндекса. Несколько курсов с нейросетями. Код на Tensorflow. Версия библиотеки там пока что старая. Для тех, кто хочет развиваться дальше.

Что посмотреть про нейронки

- Курс нейронок, который читают в ШАД и Сколтехе. Есть варианты кода на разных фреймворках. Есть видео лекций на русском и английском. Для тех, кто хочет посмотреть как читают курс по DL в ШАД.

- Бесплатный курс по tf от Google. Короткий. Покрывает весь базовый Keras. Все тетрадки выложены в colab. Есть странные интервью. Для тех, кто хочет быстро зашарить keras.

- Нейронные сети от Andrew Ng. Когда ML ещё не был таким модным, все смотрели его лекции. Для тех, кто хочет всё делать медленно и непринуждённо.

Структура курса

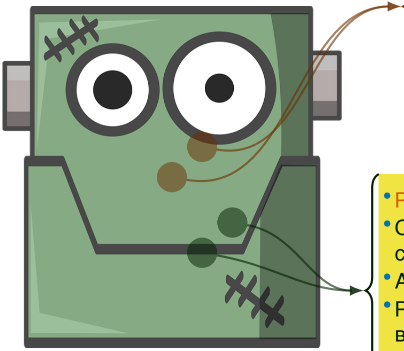

- Базовая часть курса:
- От регрессии к нейросети
- 50 оттенков градиентного спуска, Backpropagation
- Введение в Tensorflow
- Эвристики и приёмы для обучения сеток

- Разные архитектуры:
- Свёрточные сети, локализация, сегментация, перенос стиля
- Автокодировщики, генеративные модели
- Рекурентные нейронные сетки, временные ряды
- Введение в NLP, эмбединги, автопереводы, трансформеры

Фреймворки для Deep Learning

Фрэймворки

theano

TensorFlow

PYTORCH

Mila

Google

Монреальский университет (2007)

Static Computational Graph

Google (2011, открыта с 2015, с 2019 tf 2.0)

~~Static~~ Dynamic Computational Graph

Facebook (2016)

Dynamic Computational Graph

Обёртки

Сначала обёртка для Theano, потом для Tensorflow, сейчас фактически часть Tensorflow

Обёртка для Theano

Лекция про фрэймворки на русском (из далёкого 2017 года): https://www.youtube.com/watch?v=ghZyptkanB0

Подходы к вычислениям

Императивный подход

```
a = np.ones(10)
b = np.ones(10) * 2
c = b * a
d = c + 1
```

Сразу вычислили

Символьный подход

```
A = Variable('A')
B = Variable('B')
C = B * A
D = C + Constant(1)

# компиляция функции
f = compile(D)

# исполнение
d = f(A=np.ones(10), B=np.ones(10)*2)
```

Сначала задали граф вычислений,
а потом уже считали

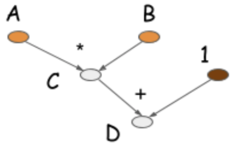

Символьный подход

+ Легко строить сеть из вычислений и автоматически искать по ней производные (быстрая и простая оптимизация)

+ Более эффективные вычисления, как по памяти, так и по скорости (на этапе компиляции можно выявить неиспользуемые переменные, найти места для переиспользования и тп)

- Довольно сложно искать ошибки из-за того, что сначала задаётся граф вычислений

Мощь библиотек (немного устарело)

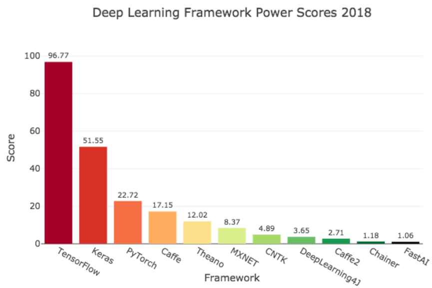

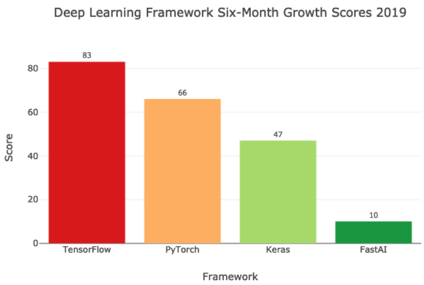

https://towardsdatascience.com/deep-learning-framework-power-scores-2018-23607ddf297a
https://keras.io/why-use-keras/

Tensorflow 2.0

https://www.tensorflow.org/beta/guide/effective_tf2

Tensorflow 2.0

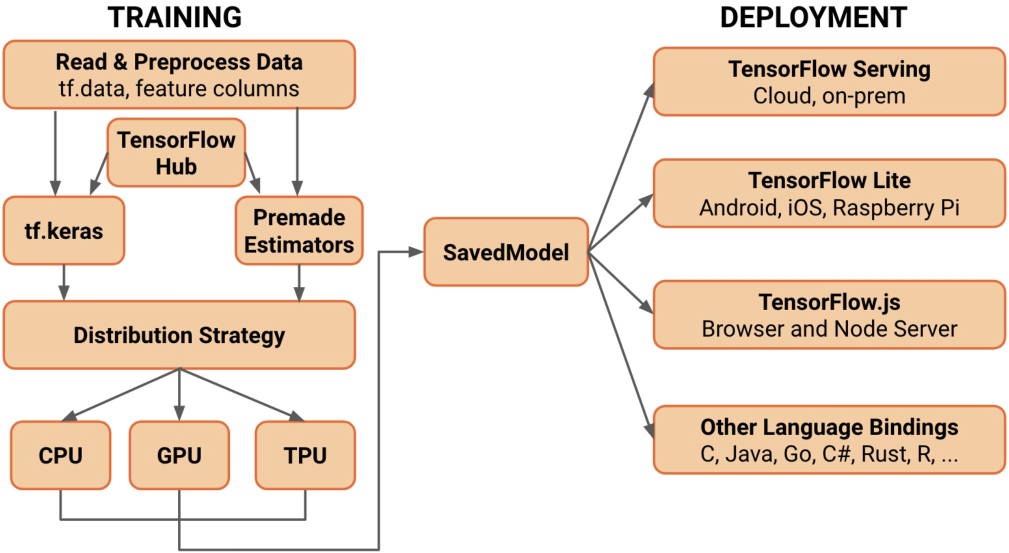

Немного истории

Первый формальный нейрон (1943)

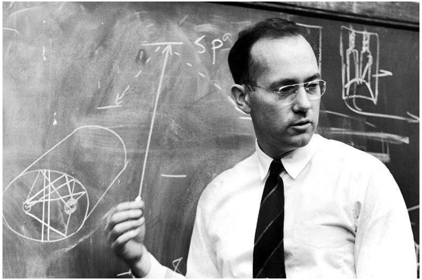

Уолтер Питтс

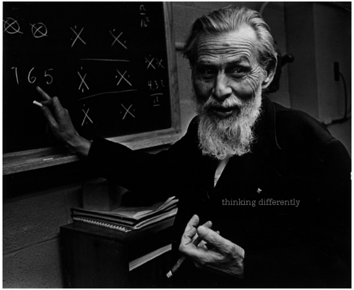

Уоррен Маккалок

Первый формальный нейрон (1958)

Фрэнк Розенблатт

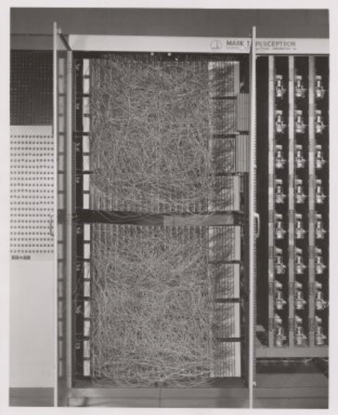

Mark I Perceptron
(Компуктер Розенблата)

Гарольд
(Мышь Розенблатта)

Дартмундский семинар (1956)

Марвин Минский

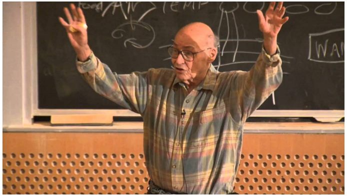

Джон Маккарти

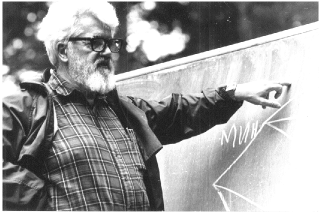

Натаниэль Рочестер

Клод Шеннон

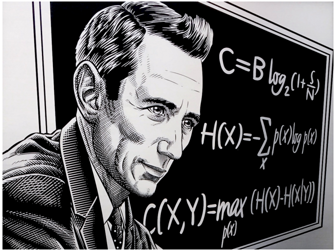


Québec
La Verendrye
Wildlife
Reserve
Алгонкинский
провинциальный
парк
Algonquin
Provincial
Park
Оттава
Ottawa
Монреаль
Montréal
Шербрук
Sherbrooke
Монктон
Moncton
Фредериктон
Fredericton
Сент-Джон
Saint John
МЭН
ВЕРМОНТ
Колледж Дартмут
Университет
Лиги плюща, открыт...
НЬЮ-ХЭМПШИР
Кингстон
Kingston
Торонто
Toronto
Миссисауга
Mississauga
Рочестер
Rochester
НЬЮ-ЙОРК
Олбани
Albany
Буффало
Buffalo
МАССАЧУСЕТС
Бостон
Boston
Провиденс
Providence
РОД-АЙЛЕНД
Нью-Йорк
New York
Питтсбург
Pittsburgh
ПЕНСИЛЬВАНИЯ
Филадельфия

Зима близко

- 1956 — Дартмунтский семинар, море оптимизма
- 1958 — Перселтрон Розенблатта
- середина 1960-х — провал крупного проекта по машинному переводу с русского на английский и наоборот
- 1969 — Марвин Минский и Сеймур Пейперт опубликовали книгу «Персептроны» с критикой

Зима наступила

- Зима искуственного интеллекта — период в истории исследований искусственного интеллекта, связанный с сокращением финансирования и снижением интереса

- Две длительные «зимы» относят к периодам 1974—1980 годов и 1987—1993 годов

- Несмотря на спад финансирования, исследования продолжались

Оттепель

- 1970-е — Расцвет экспертных систем, принимающих решения на основе большого числа правил и знаний о предметной области
- MYCIN накопила около 600 правил для идентификации вирусных бактерий и выдачи подходящего метода лечения (угадывала в 69% случаев, лучше любого начинающего врача)
- 1980-е — появилось много разных архитектур
- 1980-е — алгоритм обратного распространения ошибки (backpropagation) позволил обучать сети за линейное время
- Ренессанс нейронных сетей

Зима близко

- Новая волна оптимизма
- 1986 — один из первых AI-отделов экономил компании DEC около 10 миллионов долларов в год
- Завышенные ожидания снова лопнули
- 1990-е — ударными темпами развивается классическое машинное обучение

Революция (2005-2006)

Джеффри Хинтон
(университет Торонто)

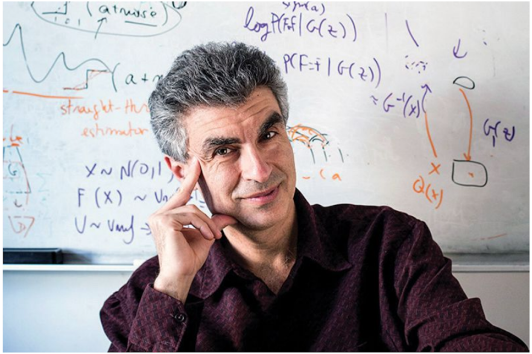

Йошуа Бенджи
(университет Монреаля)

Революция

- 2005-2006 — группы Хинтона и Бенджи научились обучать глубокие нейросетки
- Накопилось больше данных! Огромные данные!
- Компьютеры стали на порядки мощнее! Появились крутые GPU!
- На больших данных и мощностях заработали старые архитектуры
- Появились новые алгоритмы, эвристики и подходы
- Ящик Пандоры открыт!

ImageNet

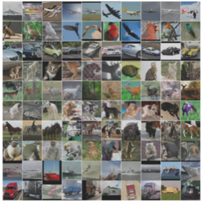

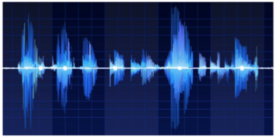

AlphaGo 4:1

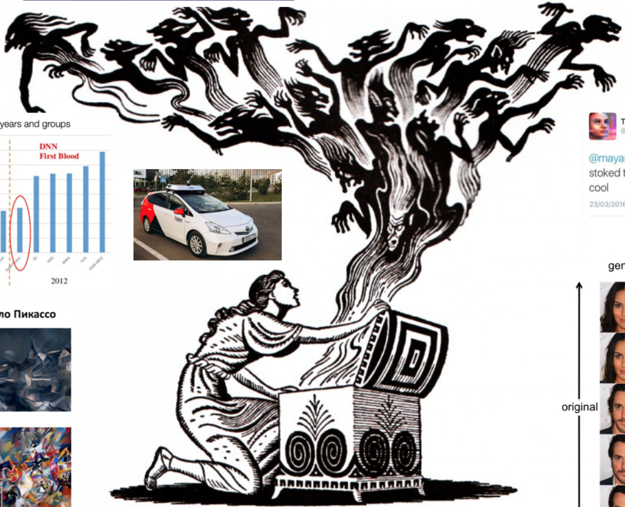

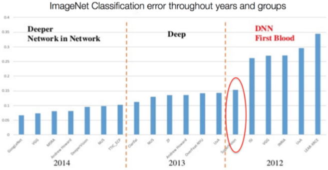

утро

вечер

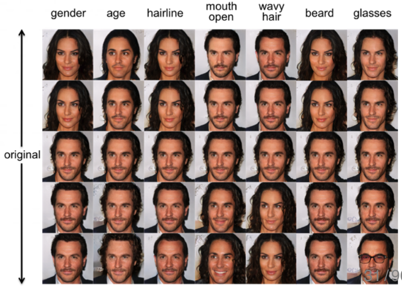

Пабло Пикассо

Винсент Ван Гог

Василий Кандинский

Новая зима близко — ???

или нет ...

- Для того, чтобы сделать большое открытие нужно несколько гениев
- Для того, чтобы внедрить его результаты нужна армия инженеров, которым не обязательно быть гениями
- Мы сделали большое открытие и только начали повсюду его внедрять
- Пример: изобретение электричества

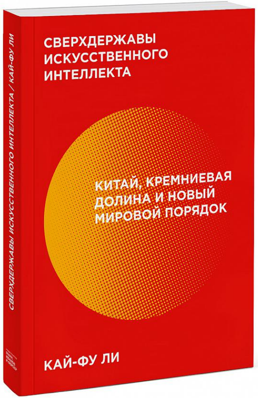

Про будущее и Китай

Важные тренды

1. Точность сетей растёт

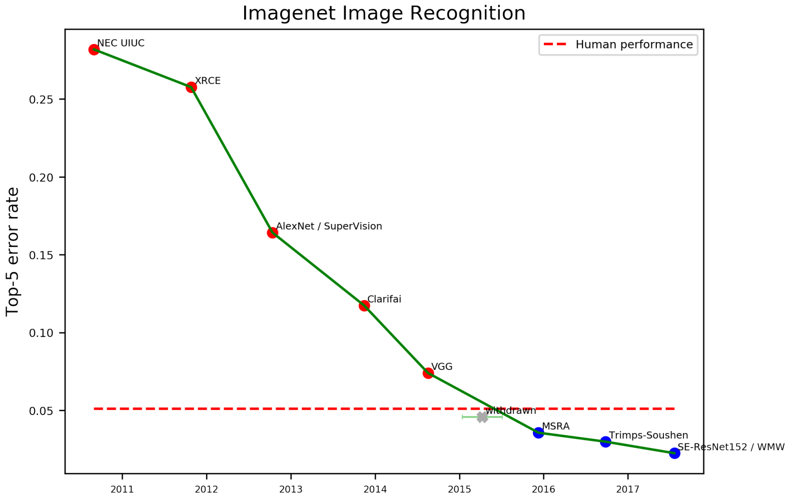

https://www.eff.org/ai/metrics

1. Точность сетей растёт

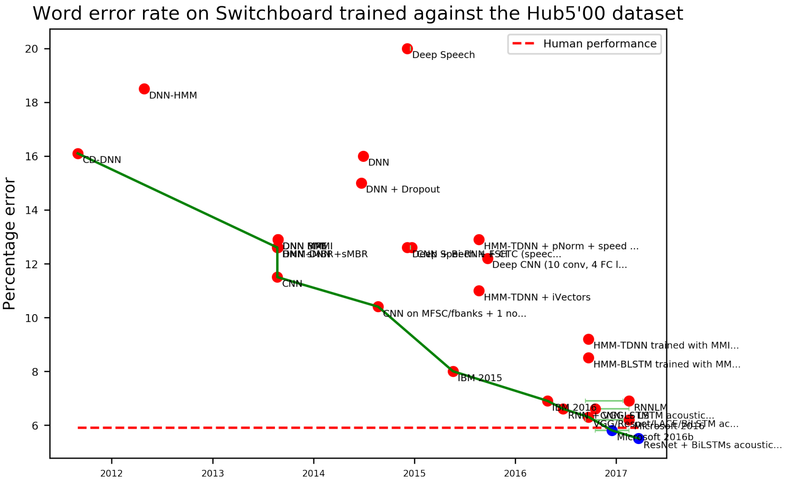

https://www.eff.org/ai/metrics

2. Сложность сетей растёт

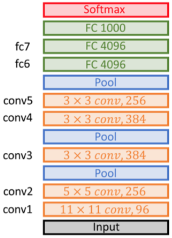

AlexNet

2. Сложность сетей растёт

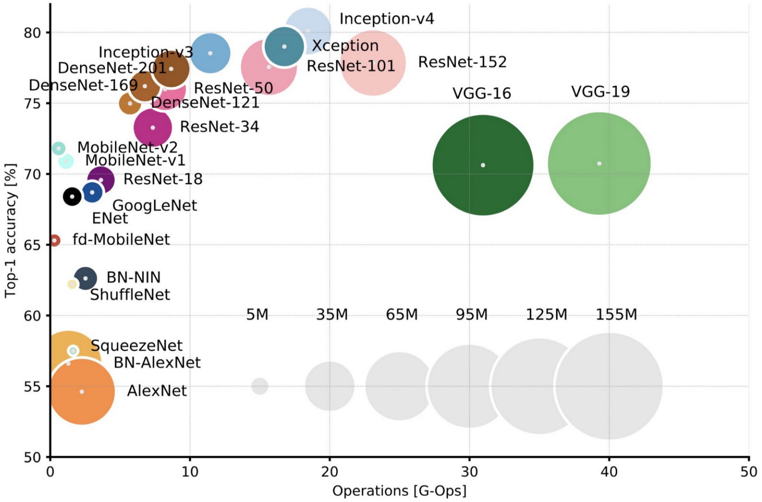

https://towardsdatascience.com/neural-network-architectures-156e5bad51ba

3. Объёмы данных растут

4,267,149,297 Internet Users in the world	**1,696,839,824** Total number of Websites	**186,645,375,538** Emails sent today

29.06.2019

4,816,061,902 Google searches today	**4,579,120** Blog posts written today	**545,680,148** Tweets sent today
5,067,684,629 Videos viewed today on YouTube	**58,968,701** Photos uploaded today on Instagram	**98,899,252** Tumblr posts today

https://www.internetlivestats.com

4. Вычислительные мощности растут

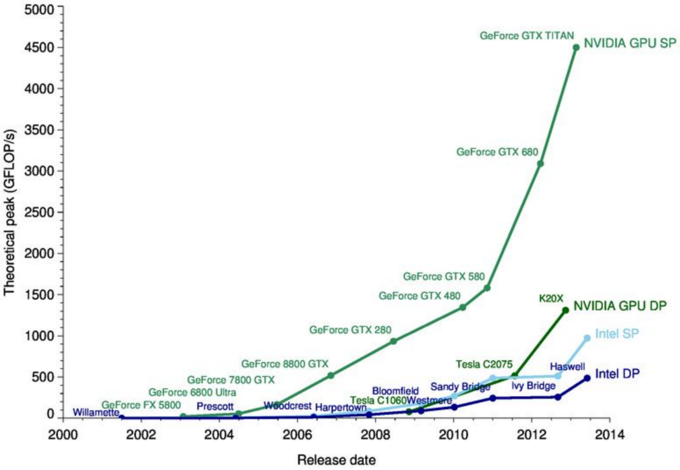

4. Почему это возможно?

https://tproger.ru/articles/cpu-and-gpu/

От регрессии к нейросетке

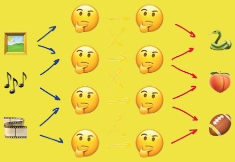

Линейная регрессия

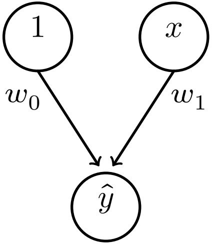

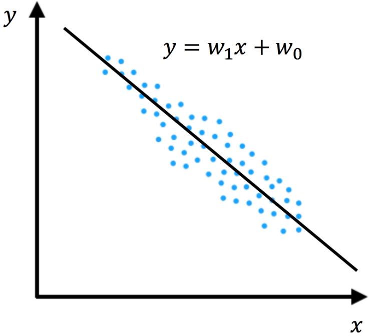

$$y_i = w_0 + w_1 \cdot x_i$$

$$y_i = \begin{pmatrix} 1 & x_i \end{pmatrix} \cdot \begin{pmatrix} w_0 \\ w_1 \end{pmatrix}$$

$$y_i = (x_i, w)$$

Линейная регрессия

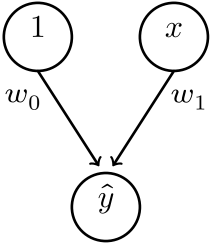

$$y_1 = w_0 + w_1 \cdot x_1$$
$$y_2 = w_0 + w_1 \cdot x_2$$
$$y_3 = w_0 + w_1 \cdot x_3$$

$$\begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \end{pmatrix} \cdot \begin{pmatrix} w_0 \\ w_1 \end{pmatrix}$$

$$y_i = w_0 + w_1 \cdot x_i$$

$$y_i = \begin{pmatrix} 1 & x_i \end{pmatrix} \cdot \begin{pmatrix} w_0 \\ w_1 \end{pmatrix}$$

$$y_i = (x_i, w)$$

Линейная регрессия (векторная форма)

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix} \qquad X = \begin{pmatrix} 1 & x_{11} & \dots & x_{1k} \\ 1 & x_{21} & \dots & x_{2k} \\ \dots & \dots & \dots & \dots \\ 1 & x_{n1} & \dots & x_{nk} \end{pmatrix} \qquad w = \begin{pmatrix} w_0 \\ w_1 \\ \dots \\ w_k \end{pmatrix}$$

Модель:

$$y = Xw$$

Оценка:

$$\hat{w} = (X^T X)^{-1} X^T y$$

Прогноз:

$$\hat{y} = X\hat{w}$$

Как обучить линейную регрессию?

- Нужно ввести штраф за ошибку:

$$MSE(w) = \frac{1}{n}\sum_{i=1}^{n}(w^T x_i - y_i)^2 \to \min_w$$

- Не для всех функция потерь бывает аналитическое решение, например для MAE из-за модуля его нет:

$$MAE(w) = \frac{1}{n}\sum_{i=1}^{n}|w^T x_i - y_i|$$

- Обычно модель обучают методом градиентного спуска

Про метрики для регрессии:
https://alexanderdyakonov.files.wordpress.com/2018/10/book_08_metrics_12_blog1.pdf

А что если...

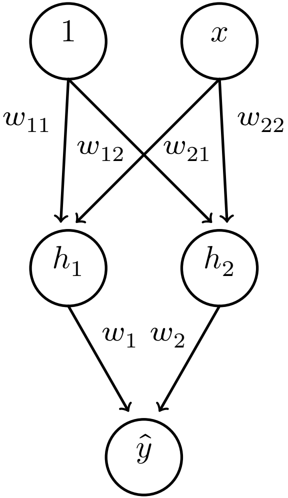

$$h_{1i} = w_{11} + w_{21} \cdot x_i$$
$$h_{2i} = w_{12} + w_{22} \cdot x_i$$

$$y_i = w_1 \cdot h_{1i} + w_2 \cdot h_{2i}$$

$$h = X \cdot W_1$$
$$y = h \cdot W_2$$

Норм идея?

А что если...

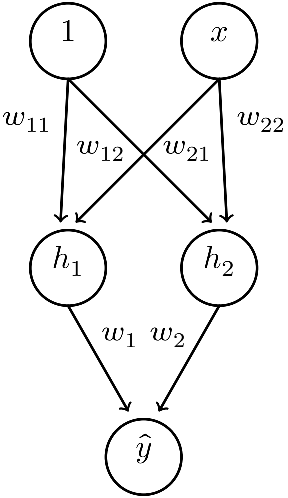

$$\begin{aligned} y &= w_1 \cdot h_1 + w_2 \cdot h_2 = \\ &= w_1 \cdot (w_{11} + w_{21} \cdot x) + w_2 \cdot (w_{12} + w_{22} \cdot x) = \\ &= \underbrace{(w_1 w_{11} + w_2 w_{12})}_{\gamma_1} + \underbrace{(w_1 w_{21} + w_2 w_{22})}_{\gamma_2} x \end{aligned}$$

Чёрт возьми! Опять линейность...

$$y = h \cdot W_2 = X \cdot W_1 \cdot W_2 = X \cdot A$$

А что если...

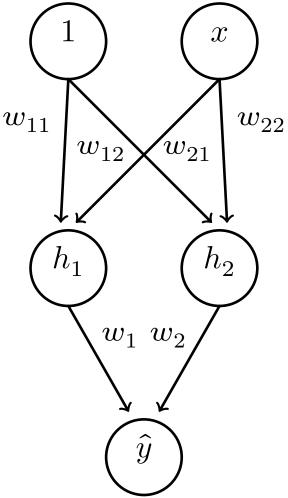

- Давайте добавим к скрытому состоянию какую-нибудь нелинейность:

$$h_{1i} = w_{11} + w_{21} \cdot x_i$$
$$h_{2i} = w_{12} + w_{22} \cdot x_i$$
$$y_i = w_1 \cdot f(h_{1i}) + w_2 \cdot f(h_{2i})$$

$$y = h \cdot W_2 = f(X \cdot W_1) \cdot W_2 \neq X \cdot A$$

Почему нельзя взять такую функцию?

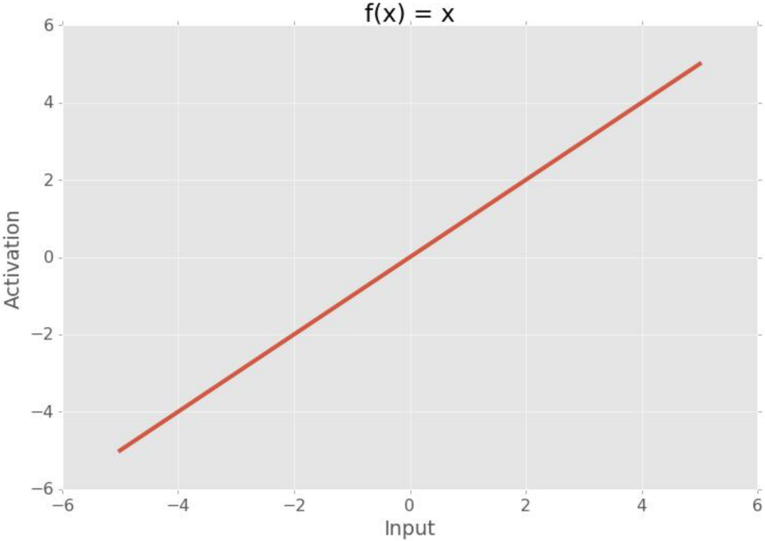

Сигмоида

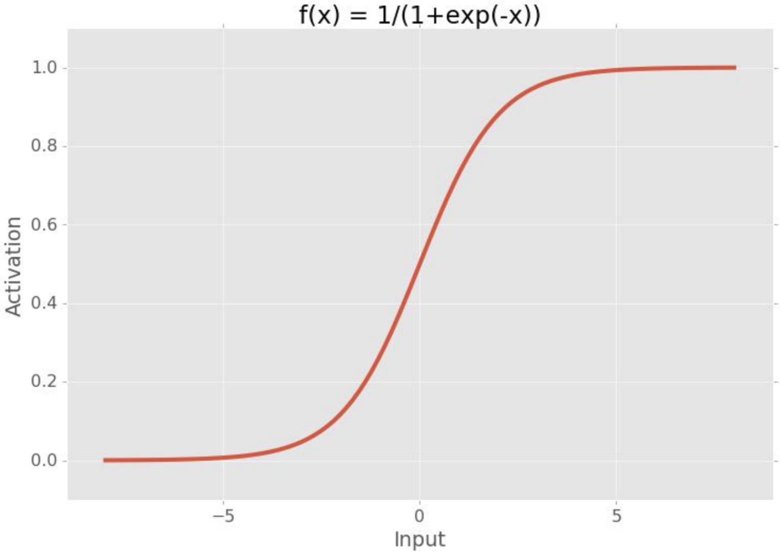

Сигмоида

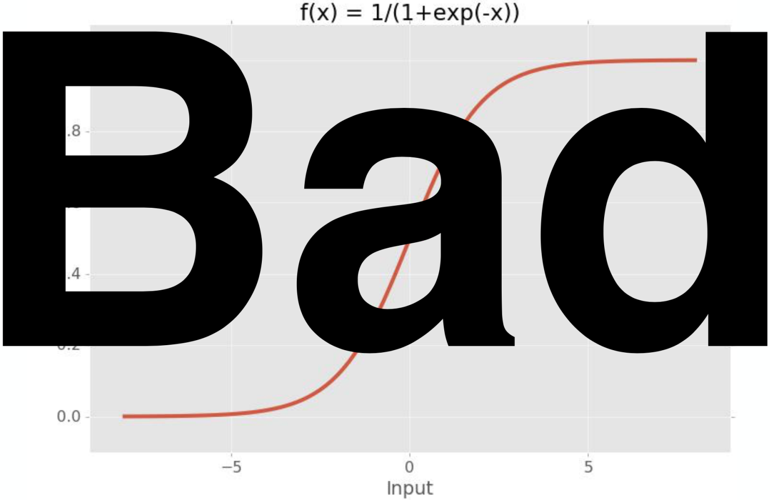

Сигмоида

- В маленьких сетках сигмоиду можно смело использовать
- В глубоких сетях из-за сигмоиды возникает паралич сети
- Про него подробнее мы поговорим чуть позже
- Нужна другая нелинейная функция активации

От линейной активации ...

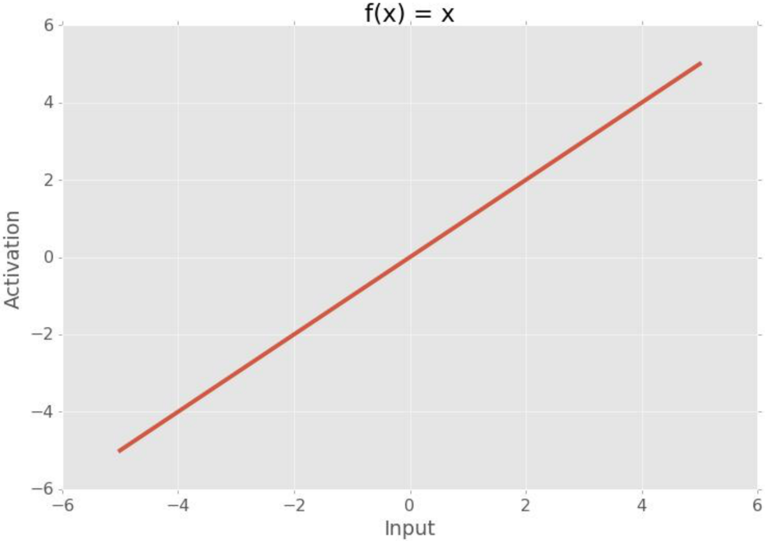

… к нелинейной

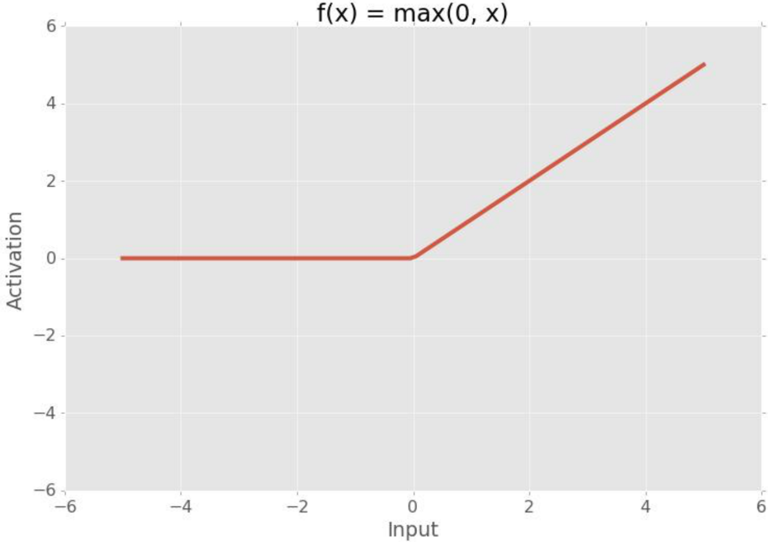

ReLU

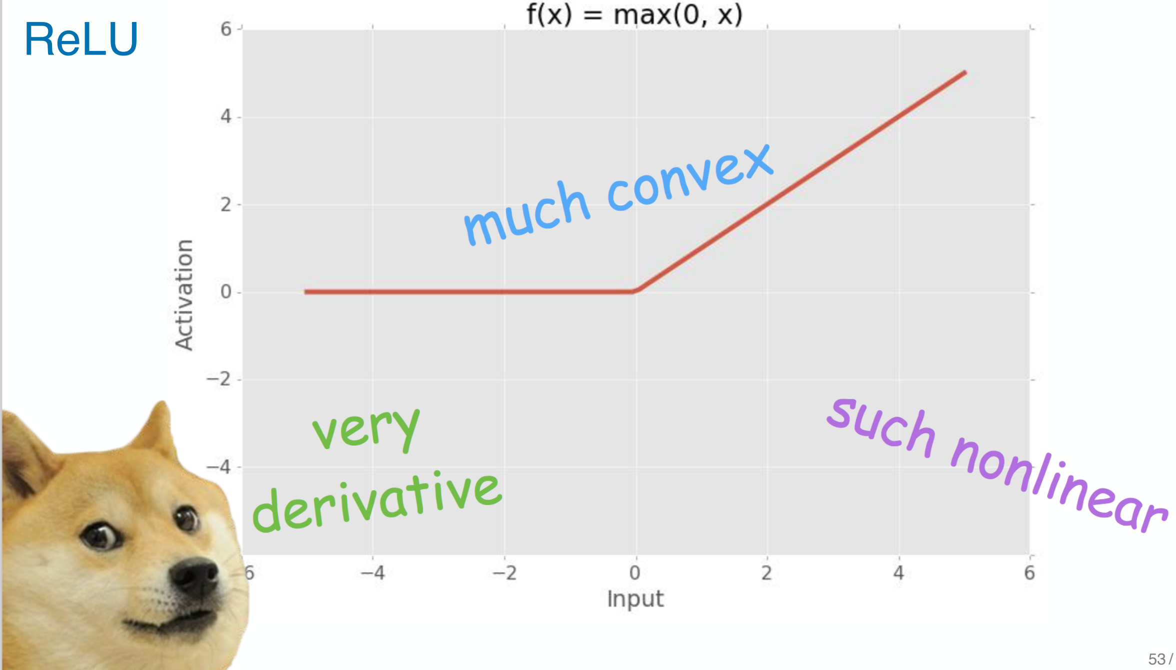
f(x) = max(0, x)
6
4
2
0
−2
−4
Activation
−6
−4
−2
0
2
4
6
Input
much convex
very
derivative
such nonlinear

ReLU

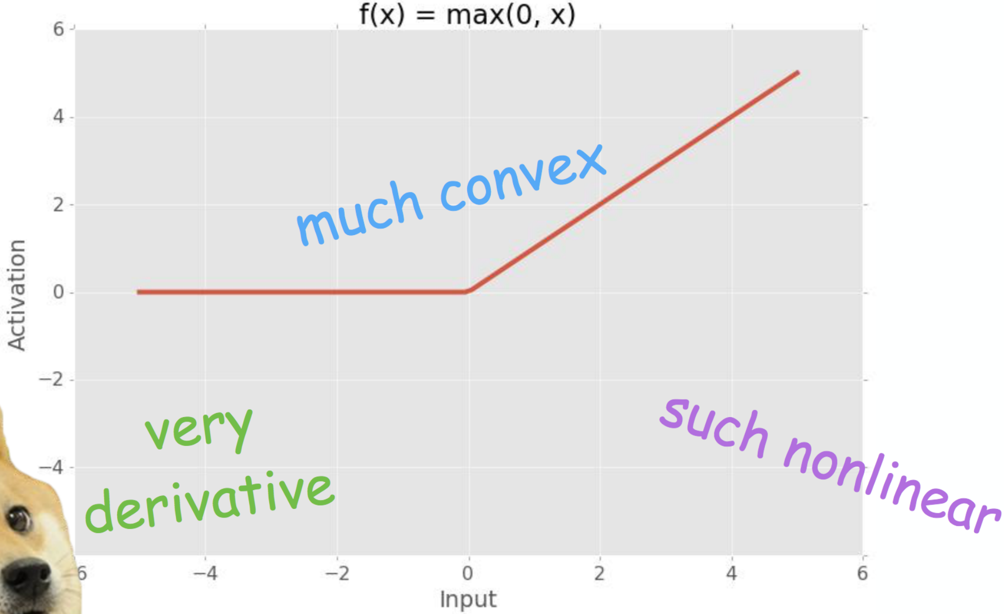

Эта шутка была мною нагло украдена у моего друга Ильи Езепова

Персептрон

Нейрон

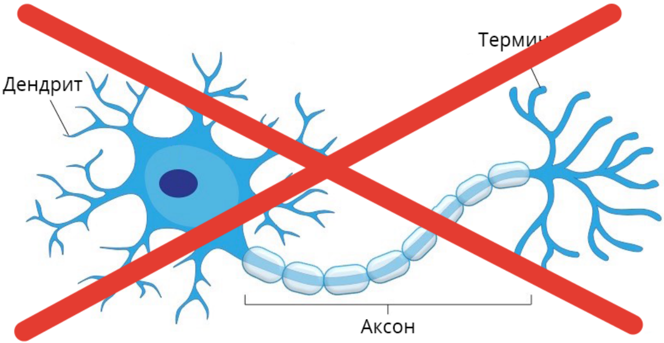

Хватит нам врать!

Мышь Розенблата

- Термин нейронная сеть пришёл из биологии, его придумали 70 лет назад

- Оказалось, что мозг устроен гораздо сложнее

- Продуктивнее думать про нейросетки, как про вычислительные графы

Не забыли его?

https://habr.com/ru/company/mailru/blog/405615/

Персептрон Розенблатта (1950)

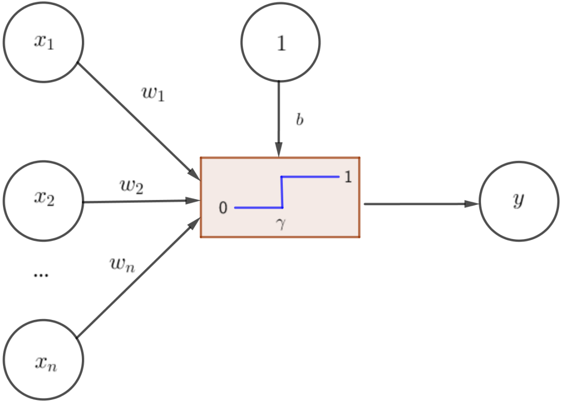

$$y = \begin{cases} 1, \text{ если } \sum w_i x_i \geq \gamma \\ 0, \text{ если } \sum w_i x_i < \gamma \end{cases}$$

Функция активации

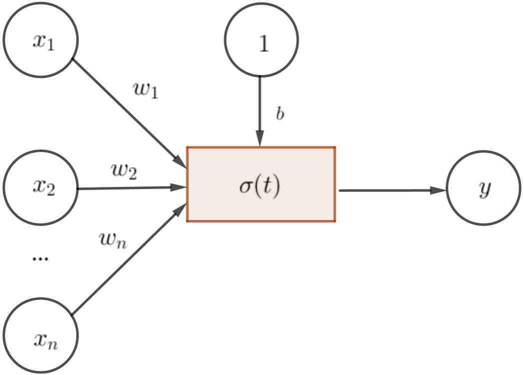

- Функция активации $\sigma(t)$ вносит нелинейность, она может быть любой

Линейная регрессия

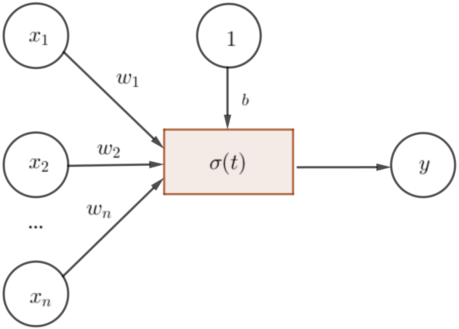

Нейрон с линейной функции активации — это линейная регрессия...

$$\sigma(t) = t$$

$$y = w_0 + w_1 \cdot x_1 + \ldots + w_n \cdot x_n$$

Логистическая регрессия

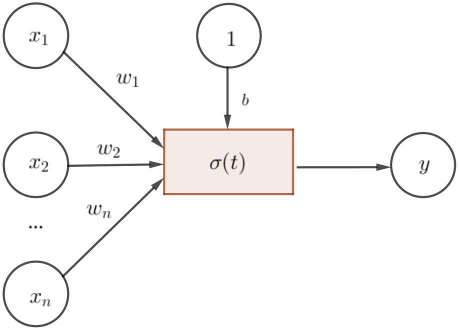

Нейрон с сигмоидом в качестве функции активации — это логистическая регрессия...

$$\sigma(t) = \frac{1}{1 + e^{-t}}$$

$$P(y = 1 \mid x) = \sigma(w_0 + w_1 \cdot x_1 + \ldots + w_n \cdot x_n)$$

Функция активации

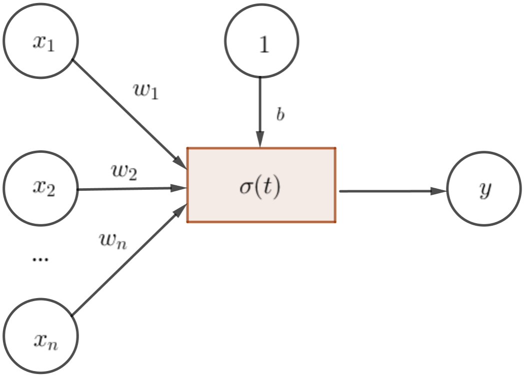

$$y = \sigma(X \cdot W)$$

Две регрессии скрепили третьей

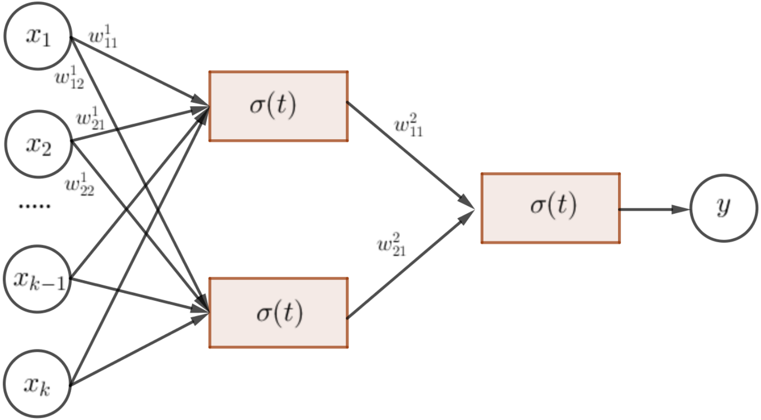

$$h_j = \sigma(w_0 + w_{j1}^1 \cdot x_1 + \ldots + w_{jk}^1 \cdot x_k)$$

$$y = \sigma(w_{11}^2 \cdot h_1 + w_{21}^2 \cdot h_2)$$

MLP (multi-layer perceptron)

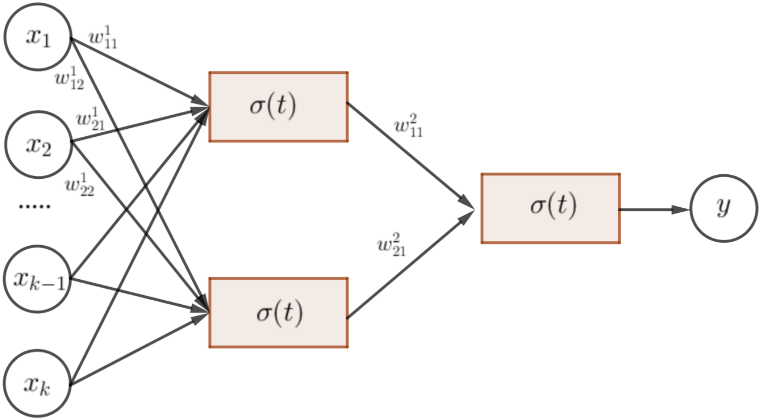

$$h = \sigma(X \cdot W)$$
$$y = \sigma(h \cdot W)$$

Армия из регрессий

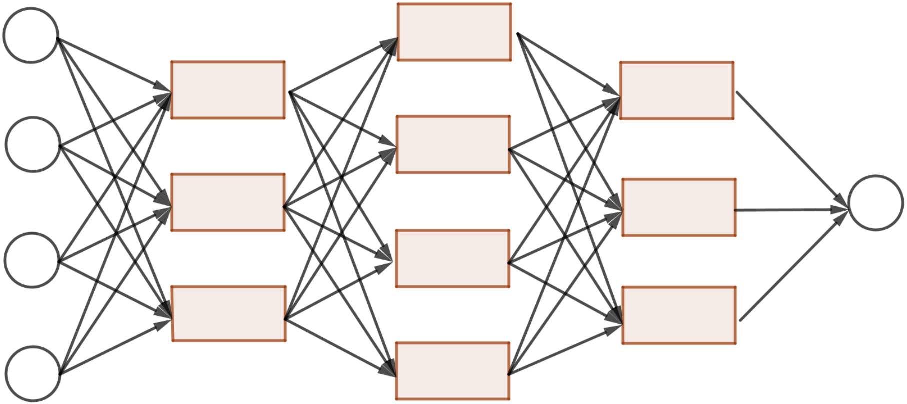

Universal Approximation Theorem (Цыбенко, 1989)

- Любая непрерывная и ограниченная функция может быть сколь угодно точно аппроксимирована нейронной сетью с одним скрытым слоем с нелинейной функцией активации нейрона.

- Любая функция может быть сколь угодно точно аппроксимирована нейронной сетью с двумя скрытыми слоями с нелинейной функцией активации нейрона.

- Что ещё можно пожелать?

Графическое доказательство теоремы:
http://neuralnetworksanddeeplearning.com/chap4.html

Going Deeper

Мотивация

- Персептрон может решить любую проблему, но это дорого
- Глубокие архитектуры часто позволяют выразить то же самое, приблизить те же функции гораздо более эффективно, чем неглубокие
- Каждый новый слой сетки будет работать всё с более сложными фичами

Армия из регрессий

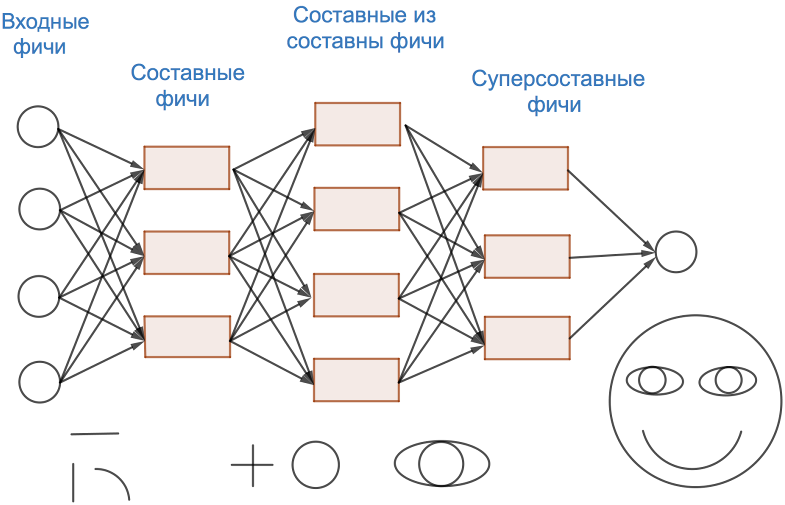

MLP не отходя от браузера

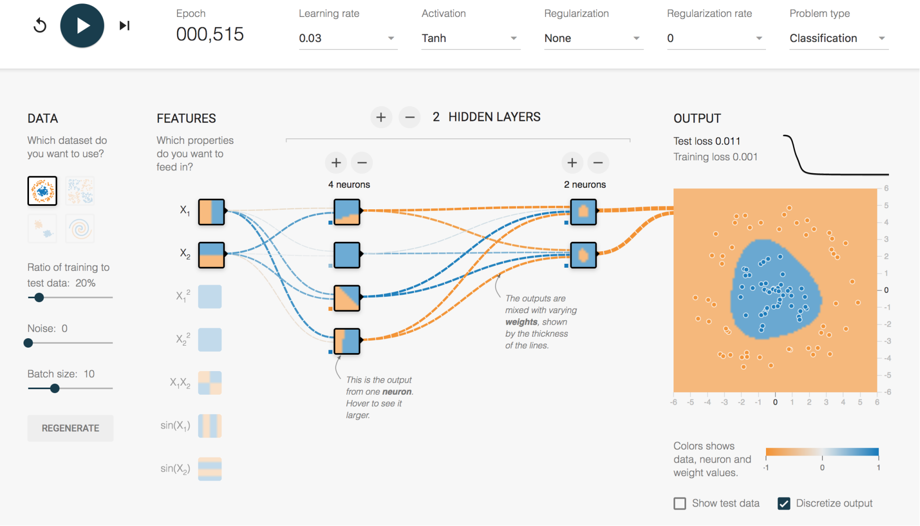

http://playground.tensorflow.org

MLP не отходя от браузера

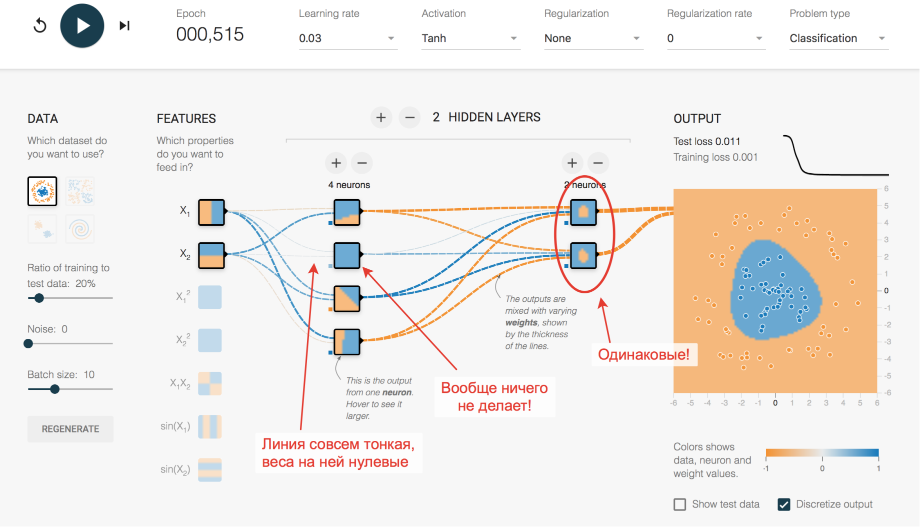

http://playground.tensorflow.org

Ещё одна аналогия

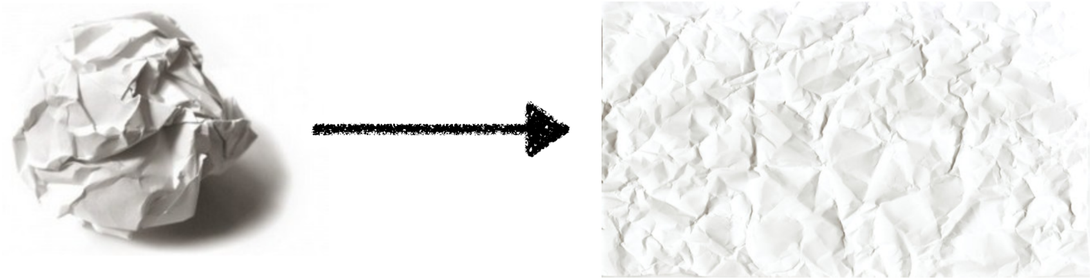

Нейросети — конструктор LEGO

Слои бывают разными

- Слой, который просто взвешивает входы называется полносвязным.

- Слои бывают очень разными. Например, Dropout: с вероятностью p отключаем нейрон. Такой слой препятствует переобучению и делает нейроны более устойчивыми к случайным возмущениям.

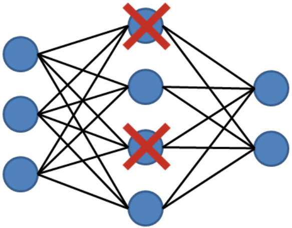

Функции активации бывают разными

Название функции	Формула $f(x)$	Производная $f'(x)$
Логистический сигмоид σ	$\frac{1}{1+e^{-x}}$	$f(x)\,(1-f(x))$
Гиперболический тангенс tanh	$\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}}$	$1-f^2(x)$
SoftSign	$\frac{x}{1+\lvert x\rvert}$	$\frac{1}{(1+\lvert x\rvert)^2}$
Ступенька (функция Хевисайда)	$\begin{cases} 0, & x<0 \\ 1, & x\geq 0 \end{cases}$	0
SoftPlus	$\log(1+e^{x})$	$\frac{1}{1+e^{-x}}$
ReLU	$\begin{cases} 0, & x<0 \\ x, & x\geq 0 \end{cases}$	$\begin{cases} 0, & x<0 \\ 1, & x\geq 0 \end{cases}$
Leaky ReLU, Parameterized ReLU	$\begin{cases} ax, & x<0 \\ x, & x\geq 0 \end{cases}$	$\begin{cases} a, & x<0 \\ 1, & x\geq 0 \end{cases}$
ELU	$\begin{cases} \alpha\,(e^{x}-1)\,, & x<0 \\ x, & x\geq 0 \end{cases}$	$\begin{cases} f(x)+\alpha, & x<0 \\ 1, & x\geq 0 \end{cases}$

Архитектуры бывают разными

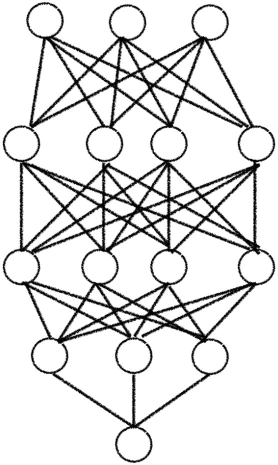

Input	
Fully connected layer (FC)	$XW + b$
ReLU	$max(0, x)$
Dropout	$Bern(p)$
FC	$XW + b$
ReLU	$max(0, x)$
FC	$XW + b$
Output	

Каждый слой — просто функция, каждая сетка — конструктор LEGO

Регрессия

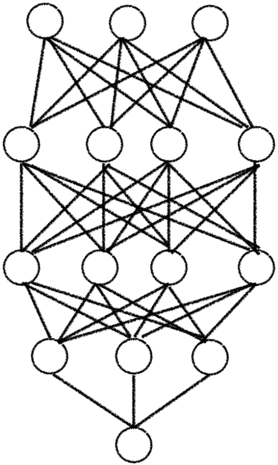

Input	
Fully connected layer (FC)	$XW + b$
ReLU	$max(0, x)$
Dropout	$Bern(p)$
FC	$XW + b$
ReLU	$max(0, x)$
FC	$XW + b$
Output	

Мультирегрессия

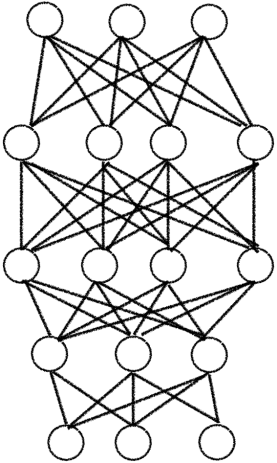

Input	
Fully connected layer (FC)	$XW + b$
ReLU	$max(0, x)$
Dropout	$Bern(p)$
FC	$XW + b$
ReLU	$max(0, x)$
FC	$XW + b$
Output	

Классификация

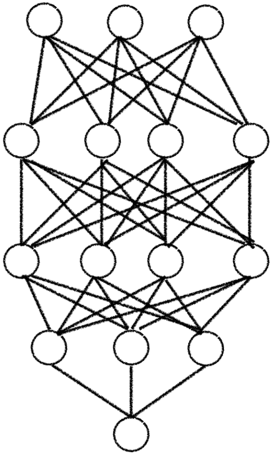

Layer	
Input	
Fully connected layer (FC)	$XW + b$
ReLU	$max(0, x)$
Dropout	$Bern(p)$
FC	$XW + b$
ReLU	$max(0, x)$
FC	$XW + b$
Sigmoid	$\sigma(x)$
Output	

Классификация

- $y \in \{0, 1\}$ — целевая переменная, X — признаки
- Модель: $y = w_0 + w_1 x_1 + w_2 x_2 + ... + w_k x_k$

Классификация

- $y \in \{0, 1\}$ — целевая переменная, X — признаки
- Модель: $y = w_0 + w_1 x_1 + w_2 x_2 + \ldots + w_k x_k$

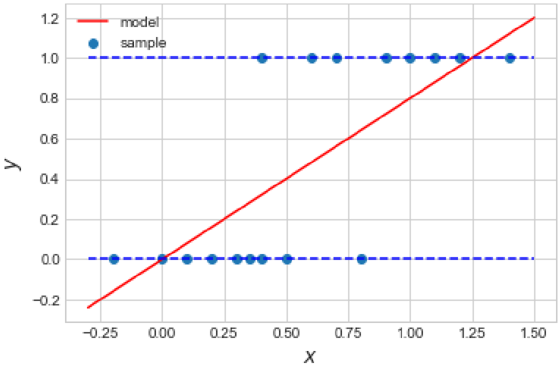

Классификация

- $y \in \{0, 1\}$ — целевая переменная, X — признаки

- Модель: $y = [w_0 + w_1 x_1 + w_2 x_2 + \ldots + w_k x_k > \gamma]$

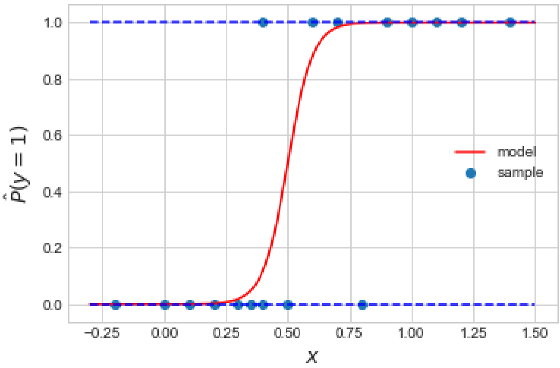

Классификация

- $y \in \{0, 1\}$ — целевая переменная, X — признаки
- Модель: $P(y = 1 \mid w) = F\left(w_0 + w_1 x_1 + w_2 x_2 + \ldots + w_k x_k\right)$

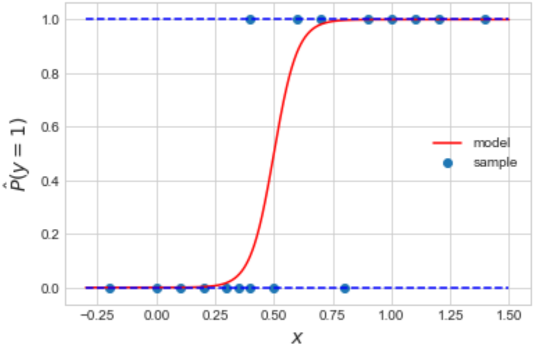

- В качестве $F(t)$ можно взять любую функцию распределения
- Если взять сигмоиду, модель будет интерпретируемая

$$F(t) = \sigma(t) = \frac{1}{1 + e^{-t}} = \frac{e^t}{1 + e^t}$$

$$\sigma'(t) = \sigma(t) \cdot (1 - \sigma(t))$$

Сигмоида

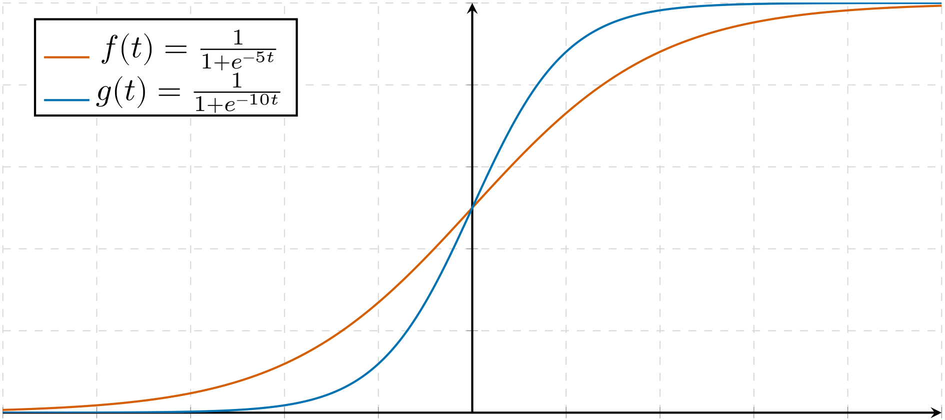

Функция потерь

- Наши y принимают значения 0 и 1
- Если $y = 1$, хотим большое $\hat{p} = \hat{P}(y = 1)$, но чем ближе $\hat{p}$ к 1, тем меньше хотим его увеличить
- Если $y = 0$, хотим большое $(1 - \hat{p})$, получается функция потерь:

$$logloss = -\frac{1}{n}\sum_{i=1}^{n} y_i \cdot ln\,\hat{p} + (1 - y_i) \cdot ln(1 - \hat{p})$$

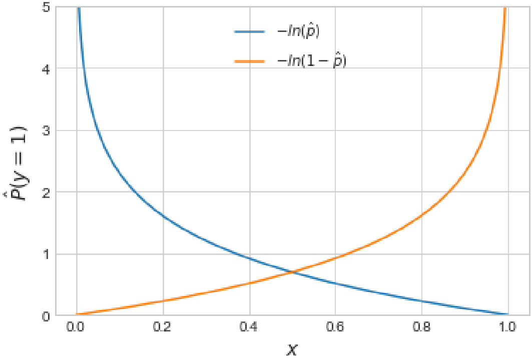

Пример: два класса

			t	$\sigma(t)$	logloss
	$\Rightarrow$	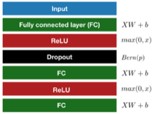	$\Rightarrow 10$	$\Rightarrow 0.99$	$\Rightarrow -(0 \cdot ln\, 0.99 + (1-0) \cdot ln(1-0.99))$
	$\Rightarrow$	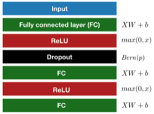	$\Rightarrow -1$	$\Rightarrow 0.26$	$\Rightarrow -(1 \cdot ln\, 0.26 + (1-1) \cdot ln(1-0.26))$

Пример: два класса

t $\quad \sigma(t) \quad$ logloss

$\Rightarrow$
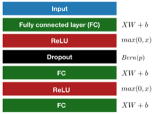

$$\Rightarrow 10 \Rightarrow [0.01, 0.99] \Rightarrow -\mathit{ln}\, 0.01$$


$\Rightarrow$
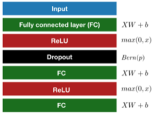

$$\Rightarrow -1 \Rightarrow [0.74, 0.26] \Rightarrow -\mathit{ln}\, 0.26$$

Мультиклассификация

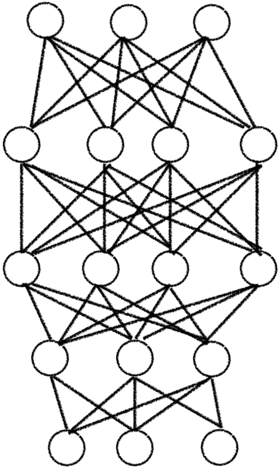

Input	
Fully connected layer (FC)	$XW + b$
ReLU	$max(0, x)$
Dropout	$Bern(p)$
FC	$XW + b$
ReLU	$max(0, x)$
FC	$XW + b$
Softmax	$softmax(x)$
Output	

Мультиклассификация

$$\mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \\ z_3 \\ \vdots \\ z_K \end{bmatrix} = \begin{bmatrix} \mathbf{w}_1^\top \\ \mathbf{w}_2^\top \\ \mathbf{w}_3^\top \\ \vdots \\ \mathbf{w}_K^\top \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix}$$

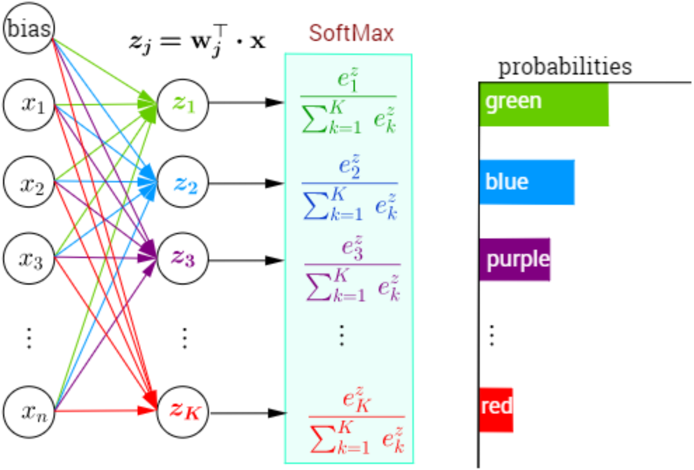

Softmax (мягкий максимум)

Много классов, $y \in 1, \dots, K$

$$(w_1^T x, \dots, w_K^T x)$$
$$\Downarrow$$
$$(e^{z_1}, \dots, e^{z_K})$$
$$\Downarrow$$
$$\left(\frac{e^{z_1}}{\sum_{k=1}^K e^{z_k}}, \dots, \frac{e^{z_K}}{\sum_{k=1}^K e^{z_k}}\right)$$

Потери (кросс-энтропия):

$$\mathit{logloss} = -\sum_{i=1}^{n}\sum_{k=1}^{K}[y_i = k] \cdot \mathit{ln}\, \frac{e^{w_k^T x_i}}{\sum_{j=1}^K e^{w_j^T x_i}}$$

Пример: три класса

t Softmax logloss

$\Rightarrow$
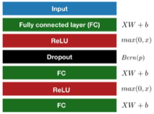

$\Rightarrow [5,4,2] \Rightarrow [0.70, 0.26, 0.04] \Rightarrow -\mathit{ln}\, 0.71$


$\Rightarrow$
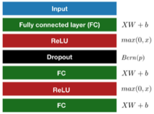

$\Rightarrow [4,2,8] \Rightarrow [0.02, 0.00, 0.98] \Rightarrow -\mathit{ln}\, 0.98$

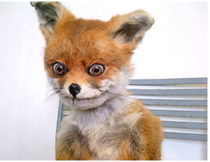
$\Rightarrow$
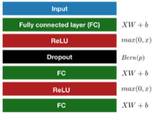

$\Rightarrow [4,4,1] \Rightarrow [0.49, 0.49, 0.02] \Rightarrow -\mathit{ln}\, 0.49$

Нейросети - конструктор LEGO

FC

ReLU

Dropout

Batch Norm

MaxPool

Convolution

1x1 Convolution

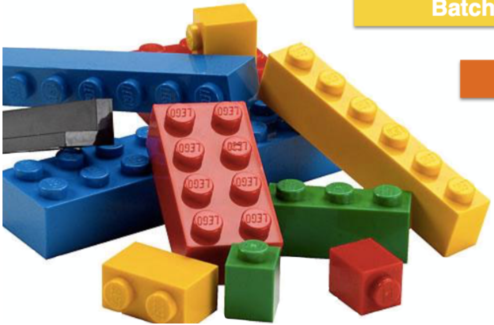

Не нейросеть, а граф вычислений

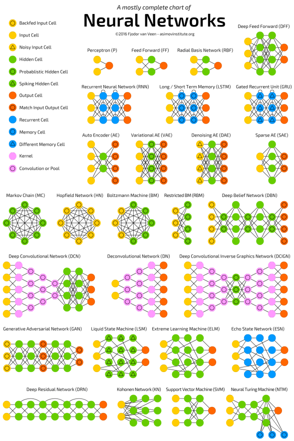

https://www.asimovinstitute.org/neural-network-zoo
https://habr.com/ru/company/wunderfund/blog/313696/

Учим свою первую нейросеть!